F2 – Virtualisering - Lagring

- Data Center Virtualization Fundamentals
  - Kapitel 1
  - Kapitel 2
  - Kapitel 9
  - Kapitel 13

- Geek-univercity.com
  - https://geek-university.com/course/vcp5-dcv-course/

STORAGE

ISCSI

NFS

FIBER CHANNEL

DATASTORES

LAGRING

BEGREPP

Hårddisk

- Spindlar
- Armar

SAN

- iSCSI – Lagringsnätverk baserat på Ethernet och TCP/IP
- FC – Lagringsnätverk baserat på Fiber Channel protokollet

IOPS

- Antal skrivningar eller läsningar av en viss datamängd per sekund.
- Ex. ”Equal read/write 8K random”, ”read 16k sequential”
- Används både för beskrivning av prestanda för Lagring och krav för Databaser för en viss applikation.

Anslutningar / Virtualisering

- LUN

HÅRDDISKAR

Anslutna seriellt/parallellt, koppar eller fiberkablar

Kan ha en eller flera skivor

Har en arm som läser och skriver

Kan läsa eller skriva vid en given tidpunkt

Snurrar i olika hastigheter 5200RPM, 7200RPM, 10000RPM, 15000RPM

Finns i 2,5” och 3,5” (vissa har haft 2,5” skivor i 3,5” chassi pga värmeutveckling)

Går sönder fysiskt efter 3-5år

FLASH

Seriellt eller parallellt anslutna

- SATA, SAS
- PCIe, NVMe

Ingen mekanik

Kan läsa och skriva samtidigt till olika NAND dies

Hållbarhet

- Max antal skrivningar till en cell ” *Today's commodity 2D MLC flash has raw wear-out in the 2,000 to 3,000 write cycle range.”*
- http://techreport.com/review/27909/the-ssd-endurance-experiment-theyre-all-dead
- 3-10% data ändras per dag i ett datacenter.

Prestanda på DISK

Gör er familjära med något prestanda testverktyg för disk. Gör lasttester före produktion. Spara resultaten för att kunna jämföra med under produktion och vid ett framtida byte av någon teknik i datacentret.

Tex.

I/O Analyzer

- https://labs.vmware.com/flings/io-analyzer

Iometer

- http://www.iometer.org

SQLIO

- Microsoft

Lagring/Disklösningar

SCSI/Hårddisk adapter med batteri (Varför då?)

HBA (host bus adapter)

Hårddiskar har en teknisk fördröjning (söktid) i sig vid läsning och skrivning till disken. Dels så snurrar diskskivan runt och dels så är det en arm som skall förflytta sig mellan olika spår för att läsa eller skriva det magnetiska innehållet.
Denna fördröjning vill man få bort. Den kunde vara så lång som 100ms. (idag 6-8ms)
Lösningen är att skrivningen sker till ett minne(cache) och då signalerar SCSI adaptern till Operativsystemet via drivrutinen att hårddisken har lagrat informationen.
Sen i efterhand så skrivs den cache-ade informationen ner till det magnetiska lagret.
För att inte informationen skall försvinna från minnet vid ett eventuellt strömavbrott så har man ett batteri till minnet som håller ca 100 timmar. När adaptern återfår sin ström så kan den kontrollera om hårddisken lyckades lagra informationen på magnetskivan eller inte och i så fall i efterhand skriva ner den.
Operativsystemet tror ju hela tiden att allt är OK och har informerat applikationen och användaren att så är fallet. Användaren har redan glömt bort var han/hon har gjort och gått hem.

Hur har man överbryggat detta problem idag (201X)

RAID

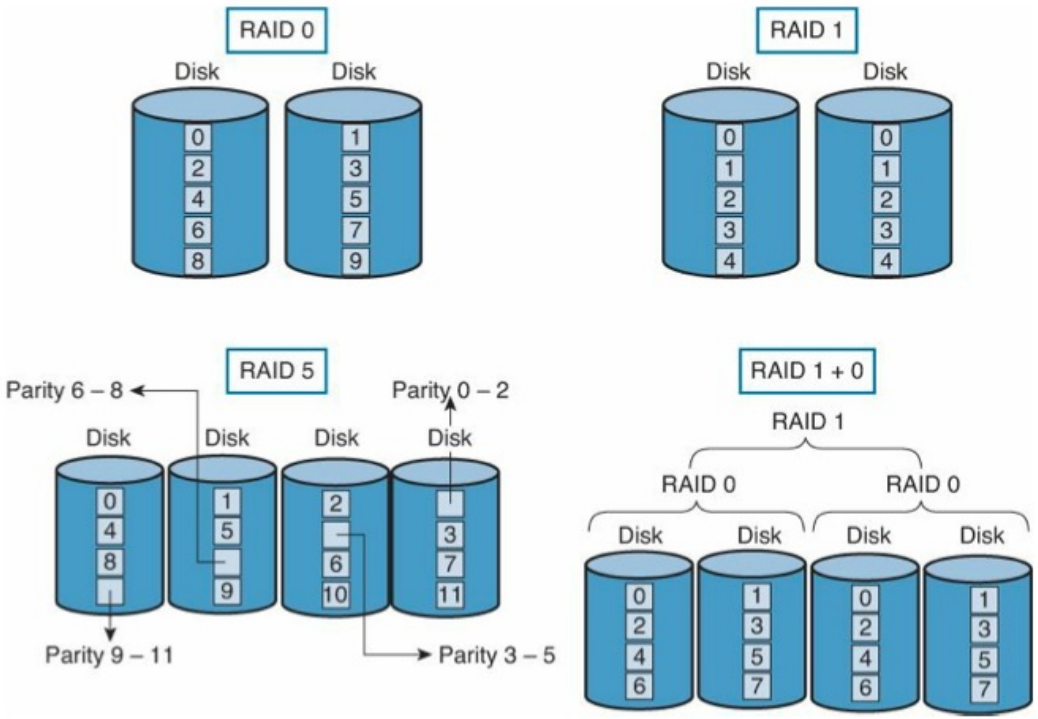

Figure 9-6 *RAID Levels*

RAID to Guest relations

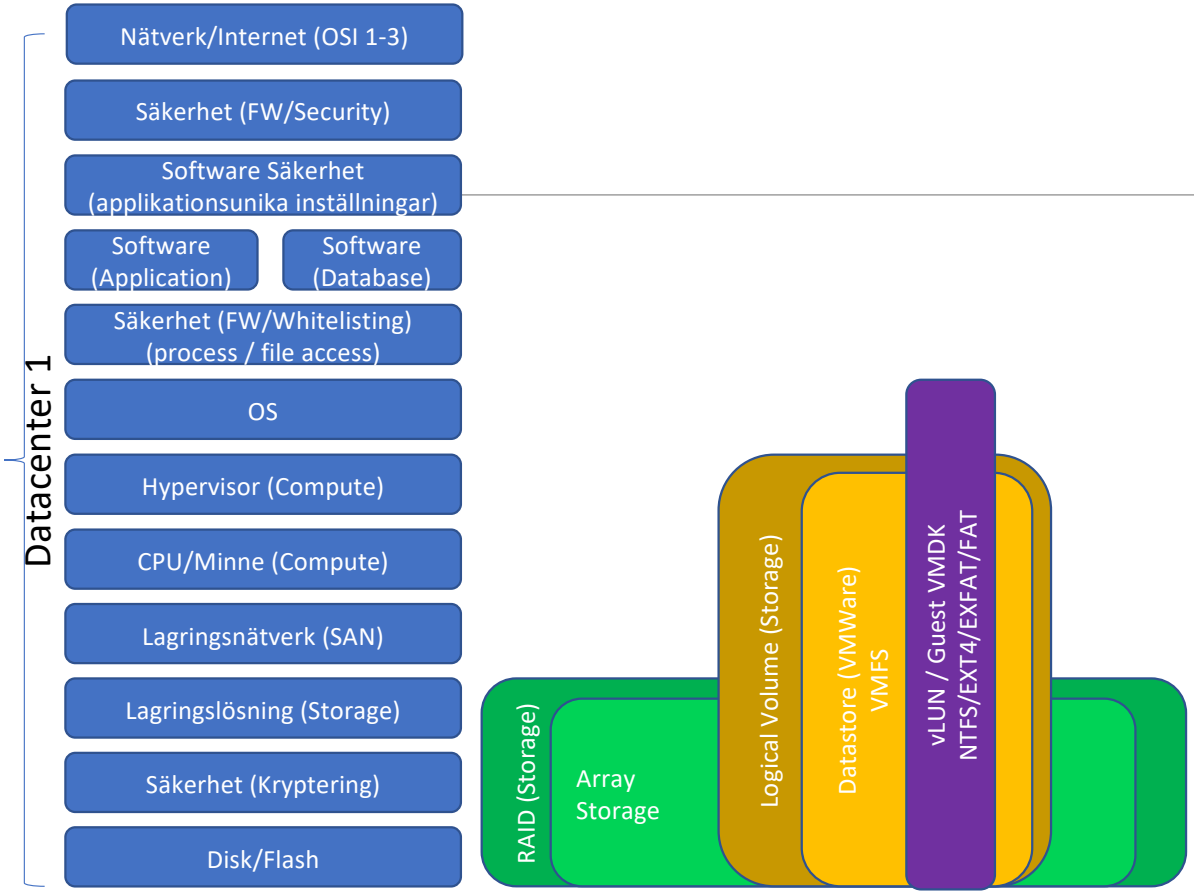

RAID Forts.

RAID

Raid är en teknik för att få flera lagringsmedia att samverka som ett enhetligt lagringsmedia gentemot processor/operativsystem.

Med RAID kan man uppfylla flera syften:
snabbare lagring
Större lagring
Säkrare lagring.

RAID0 = Striping. Flera diskar sammanförs till en enhet. (Fördelar: Snabbare och större) Nackdelar: sårbar

RAID1 = Spegling. Två och två kopplas hårddiskarna ihop så att det blir säkert. En hårddisk kan gå sönder utan att man förlorar data.

RAID10 / RAID01 = kombination av ovanstående.

RAID3,5,6 = Som RAID0 fast varje disk håller information om data på de andra diskarna så att en eller två diskar kan gå sönder utan att man förlorar data.

Erasure Coding

(EC) is a method of data protection in which data is broken into fragments, expanded and encoded with redundant data pieces and stored across a set of different locations or storage media.

The goal of erasure coding is to enable data that becomes corrupted at some point in the disk storage process to be reconstructed by using information about the data that's stored elsewhere in the array. Erasure codes are often used instead of traditional RAID because of their ability to reduce the time and overhead required to reconstruct data. The drawback of erasure coding is that it can be more CPU-intensive, and that can translate into increased latency.

Erasure coding can be useful with large quantities of data and any applications or systems that need to tolerate failures, such as disk array systems, data grids, distributed storage applications, object stores and archival storage. One common current use case for erasure coding is object-based cloud storage.

Lagringsnätverk

SAN / FC (FibreChannel), iSCSI, NFS Nät

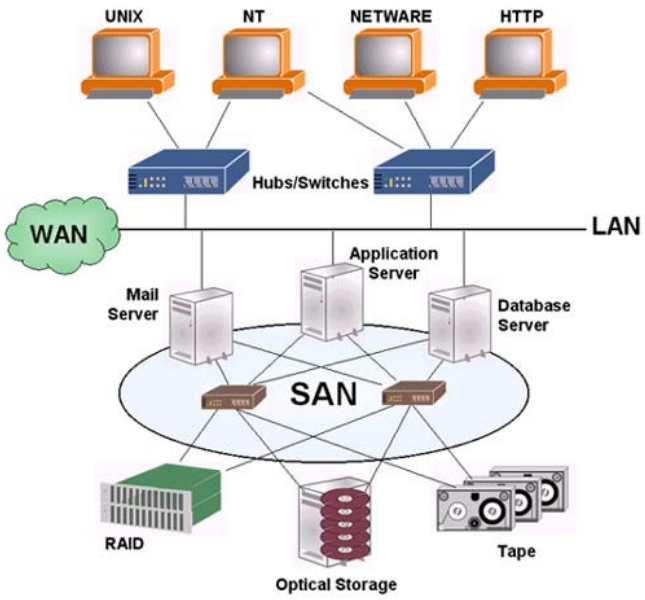

SAN (Storage Area Network)
Anslutningsgränsnitt för lagringsnät/enheter

Anslutningar och protokoll för lagringnätverk:

FC (FibreChannel)

FCoE (FibreChannel over Ethernet)

NVMe over FC

iSCSI (SCSI over IP)
Ethernet

NFS (Fildelning över TCP/IP)
Ethernet

Anslutningar och protokoll för lagringsenheter:

ATA

SATA

SCSI

SAS

NVMe (PCI)

SAN forts.
Lär er de olika förkortningar och deras relation till varandra.

FC: Fiberbaserat lagringsnätverk för SCSI meddelanden i ett switchat nät.

FCoE: Som ovan fast man kan använda speciell 10Gbit Ethernet Switch från tex. Cisco för att minska behovet av speciell utrustning(SAN-Switch).
Ca 3% av bandbredden försvinner jämfört med FC.

iSCSI: SCSI meddelanden över IP(TCP).
Man kan använda standard Ethernet/IP baserat nätverk för att få åtkomst till lagringslösningen. Ca 40% av bandbredden försvinner pga IP-Headern och TCP jämfört med FC.

NVMe over FC: 50% högre IOPS och 30% lägre latencey(fördröjning) jämfört med FC

ATA: parallell anslutning av hårddisk till Kontroller. Vanligast i äldre PC

SATA: Seriell ATA.

SAS: Seriell SCSI anslutning.

Fildelningstjänster

HTTP

FTP

NFS

SMB/CIFS

S3 (HTTP-basead)

SCP (SSH)

Vad är det för skillnad i olika versioner som är unikt för lagringsnätverk?

iSCSI

- Grunder
  - Adressering
    - IP + iSCSI Qualified Name (IQN)
      iqn.1992-01.com.example:storage:diskarrays-sn-a8675309
    - Target och Initiator
- Säkerhet
  - Inloggning mot LUN
  - VLAN - Jämför med Zoning i FC
  - Confidentiality and integrity[edit]
    - For the most part, iSCSI operates as a cleartext protocol that provides no cryptographic protection for data in motion during SCSI transactions. As a result, an attacker who can listen in on iSCSI Ethernet traffic can:
      - Reconstruct and copy the files and filesystems being transferred on the wire
      - Alter the contents of files by injecting fake iSCSI frames
      - Corrupt filesystems being accessed by initiators, exposing servers to software flaws in poorly tested filesystem code.

iSCSI forts.

MultiPath

- Möjliggör användandet av två eller fler fysiska Ethernet för iSCSI.
- Ökar bandbredden
- Skapar redundans.
- http://www.vmware.com/content/dam/digitalmarketing/vmware/en/pdf/techpaper/vmware-multipathing-configuration-software-iscsi-port-binding-white-paper.pdf
  - *”The storage and the VMkernel port must have an IP address in the same network”.*

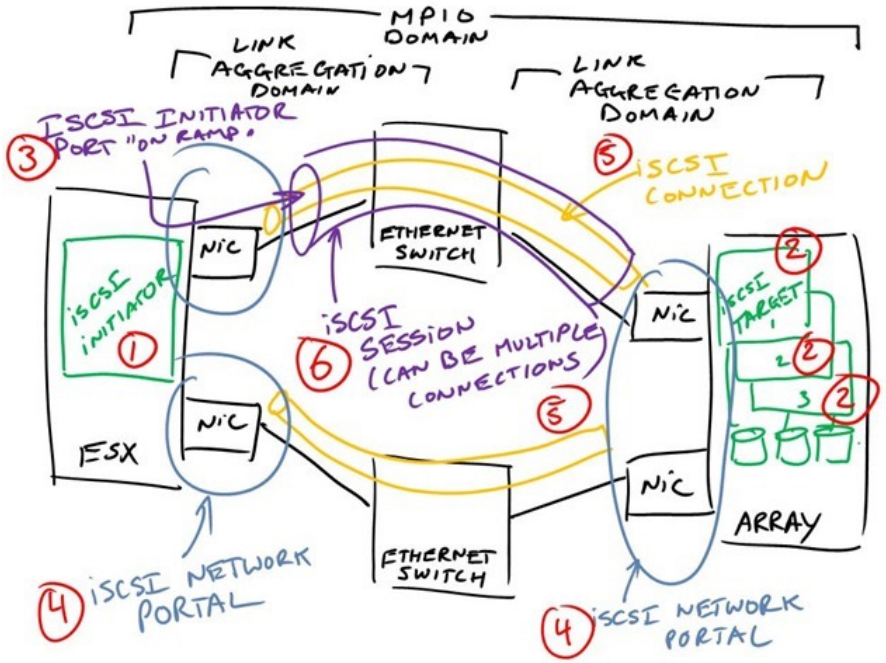
MPIO DOMAIN
LINK AGGREGATION DOMAIN
LINK AGGREGATION DOMAIN
3 ISCSI INITIATOR PORT "ON RAMP"
5 ISCSI CONNECTION
ISCSI INITIATOR
1
NIC
NIC
ESX
ETHERNET SWITCH
ETHERNET SWITCH
6 ISCSI SESSION (CAN BE MULTIPLE CONNECTIONS)
5
NIC
NIC
ISCSI TARGET
2
2
2
ARRAY
4 ISCSI NETWORK PORTAL
4 ISCSI NETWORK PORTAL

iSCSI fördjupning

X3 - A Multivendor Post to help our mutual iSCSI customers using VMware - Virtual Geek

- Beskriver hur iSCSI beter sig i IP-Nätet

X3 - Så bygger du ett san med iscsi – TechWorld

X3 - frazier_01_0407

- Etherchannel/LACP/802.3ad Link Aggregation
  Fördelar och nackdelar

Data Center Virtualization Fundamentals

- Figure 2-4 Ethernet Standards Data Rate and Cabling Technologies

DRIVRUTINER

Drivrutiner för ESXi/Hypervisorn

- Hypervisorn behöver små program för att kunna använda hårdvaran (drivrutiner) som är ansluten.
  - Här tänker vi oss Fiber Channel – HBA kortet.
  - Det finns Ethernetkort med hårdvarustöd för iSCSI (tex. HP)
- Hypervisorn skapar virtuell hårdvara som delas ut till gästoperativen.

Gästoperativsystemet

- Måste ha drivrutiner för de virtuella hårdvarorna som är utdelade för att kunna använda dem.

Olika drivrutiner och virtuell hårdvara konsumerar olika mycket CPU i Gästen och Hypervisorn

- Snålast är **Paravirtualized** (VMXNET3 för Ethernet och **Paravirtual** SCSI för Lagring)

Linux Storage Stack

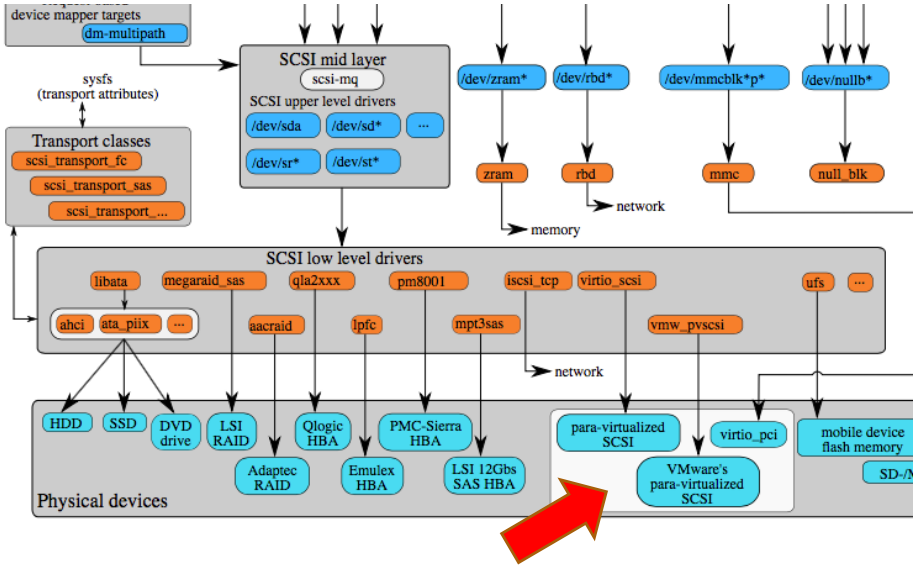

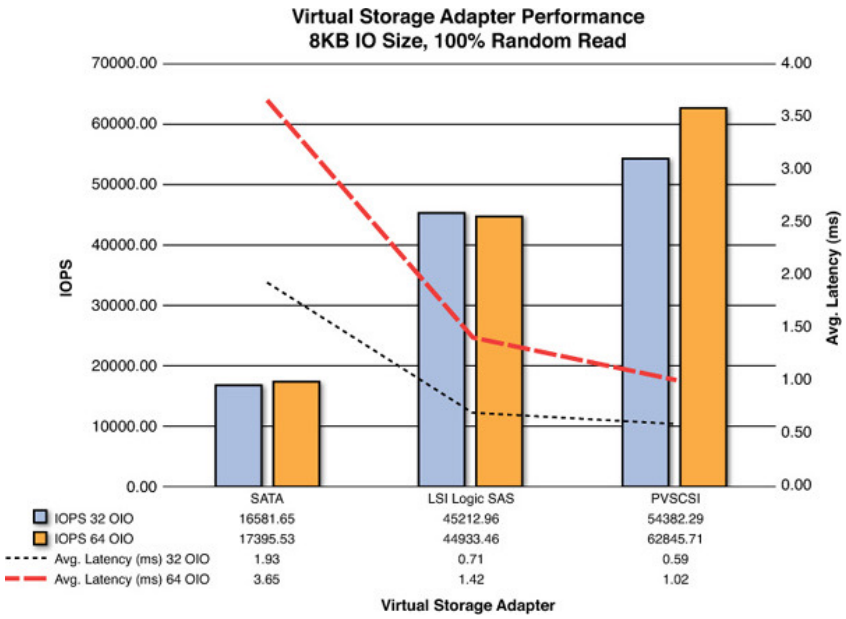

DRIVRUTINER

Thick vs Thin Disks

Utdelning av disk till Hypervisorn och Gästen.

Till Hypervisorn

- Disk delas ut i lagringslösningen som LUN's.
- De kan vara Thick eller Thin beroende på lagringslösning.
- Hypervisorn formaterar dem med VMFS5 filsystem som sen kan delas mellan flera Hypervisor's.

Till Gästen

- Disk delas ut i Hypervisorn till Gästen via virtuella HBA-er som LUN's eller tom. IDE-ATA diskar.
- De kan vara Thick eller Thin.

https://blogs.vmware.com/vsphere/2014/05/thick-vs-thin-disks-flash-arrays.html

Bra video från 2018: https://youtu.be/kpXLWoeCKWA

Thick vs Thin Disks Forts.

Windows 2012R2 stödjer och kan hantera Thin om följande uppfylls:

- VMDK must be thin provisioned
- Virtual Machine Hardware version must be 11 (ESXi 6.0)
- The advanced setting EnableBlockDelete must be set to 1
- The Guest OS must be able to identify the disk as thin (Windows 2012 [updated 30-Oct-2015] uses the B2 mode page to achieve this)

X2 - vSphere 6.0 Storage Features Part 8- VAAI UNMAP changes

https://kallesplayground.wordpress.com/2014/04/03/storage-reclamation-part1/

Ytterligare funktioner i lagringslösningar

I och med Flash-lagring så uppstår en möjlighet att bearbeta informationen som skall lagras på disk utan att det fördröjer svarstiden nämnvärt.

Lagringssystem med magnetdisk har en genomsnittlig svarstid på ca 6ms och Flashlagringslösningar ca 0,5ms inklusive bearbetningstid av följande funktioner:

Deduplisering

- Lagringslösningen jämför information som skall lagras med redan lagrad information. Om informationen som skall lagras är identisk med redan lagrad information så skapas bara en pekare i ett register. Utrymme sparas

Komprimering

- Motsvarar ZIP av filer. Lagringslösningen komprimerar all information som lagras.

Kryptering

- All information som lagras krypteras.

Storage Design SQL i VMWare

X5 - SQL Server Database and Guest OS Storage Design Ch6

SQLIO

PRESTANDATESTER MED SQLIO PÅ HP FLASHLAGRING

Prestandatester på Lagring

https://www.brentozar.com/archive/2008/09/finding-your-san-bottlenecks-with-sqlio/

Ändra i infrastrukturen så att Lagringen är ansluten på 100Mbit resp 1Gbit och gör samma prestandatester.

Kontrollera CPU-utnyttjande i ESXi (esxtop)

SQLIO på HP AllFlash 4k block

```
C:\sqlio>sqlio.exe -kR -t8 -s20 -o8 -fsequential -b4 -BH -LS f:\testfile.dat
sqlio v1.5.SG
using system counter for latency timings, 2338334 counts per second
8 threads reading for 20 secs from file f:\testfile.dat
        using 4KB sequential IOs
        enabling multiple I/Os per thread with 8 outstanding
        buffering set to use hardware disk cache (but not file cache)
using current size: 24576 MB for file: f:\testfile.dat
initialization done
CUMULATIVE DATA:
throughput metrics:
IOs/sec: 161881.35
MBs/sec:   632.34
latency metrics:
Min_Latency(ms): 0
Avg_Latency(ms): 0
Max_Latency(ms): 52
histogram:
ms: 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24+
%: 100  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0
```

SQLIO på HP AllFlash 16k block

```
C:\sqlio>sqlio.exe -kR -t8 -s20 -o8 -fsequential -b16 -BH -LS f:\testfile.dat
sqlio v1.5.SG
using system counter for latency timings, 2338334 counts per second
8 threads reading for 20 secs from file f:\testfile.dat
        using 16KB sequential IOs
        enabling multiple I/Os per thread with 8 outstanding
        buffering set to use hardware disk cache (but not file cache)
using current size: 24576 MB for file: f:\testfile.dat
initialization done
CUMULATIVE DATA:
throughput metrics:
IOs/sec: 133266.25
MBs/sec:  2082.28
latency metrics:
Min_Latency(ms): 0
Avg_Latency(ms): 0
Max_Latency(ms): 6
histogram:
ms: 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24+
%: 100  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0
```

Blockstorlekar

Windows NTFS kan formateras i tex. 1k, 4k, 16k och uppåt.

VMFS5 – ”vSphere 5.0 and later releases have a block size of 1 MB only.”

- https://kb.vmware.com/selfservice/microsites/search.do?language=en_US&cmd=displayKC&externalId=1003565

Flash har en blockstorlek på 64kByte

En hårddisk har en blockstorlek på 4k idag.

- 4096-byte (4 KiB) sectors

Enheter

Byte / Bit

K, M, G, T, P

KiB - Kibibyte

TiB – Tebibyte

v·t·e	Units of information
Base unit	bit
Platform-dependent units	nibble · byte · syllable · parcel · word
Platform-independent units	unibit (1) · dibit (2) · tribit (3) · quadbit (4)
	quartet (4) · sextet (6) · octet (8) · hextet (16)
	declet (10) · doublet (16) · quadlet (32) · octlet (64) · hexlet (128)
	triad (3) · tetrad (4) · pentad (5) · hexad (6) · heptad (7) · octad (8)
	slab (12) · catena (24)
Traditional bit units	kilobit · megabit · gigabit · terabit · petabit · exabit · zettabit · yottabit
Traditional byte units	kilobyte · megabyte · gigabyte · terabyte · petabyte · exabyte · zettabyte · yottabyte
IEC bit units	kibibit · mebibit · gibibit · tebibit · pebibit · exbibit · zebibit · yobibit
IEC byte units	kibibyte · mebibyte · gibibyte · **tebibyte** · pebibyte · exbibyte · zebibyte · yobibyte